

Reporte de Sustentación y Defensa - Taller 06

Aprendizaje Supervisado: Regresión y Predicción de Precios de Autos Usados

Estudiante: Pablo Montenegro
Bootcamp: Ciencia de Datos (Edición 2026)
Proyecto: Avalúo de Autos Usados (`cardekho.csv`)
Fecha de Emisión: Octubre de 2026

1. Introducción y Contexto del Proyecto

Este documento constituye la memoria oficial de sustentación del Taller 06. Su propósito es detallar la arquitectura metodológica, la ingeniería de características, los fundamentos de los bloques de código ejecutados y la evaluación comparativa de tres modelos de aprendizaje supervisado aplicados a la estimación de precios comerciales de vehículos.

2. Explicación Detallada de Bloques de Código

Bloque 0: Importación de Librerías Esenciales

Objetivo: Cargar las dependencias fundamentales de Python para el procesamiento de datos y modelado predictivo.
Detalles y Funcionalidad: Se importaron *Pandas* y *NumPy* para el manejo matricial, *Matplotlib* y *Seaborn* para visualización estadística, herramientas de *Scikit-Learn* para partición (`train_test_split`) y escalado (`StandardScaler`), junto con las clases de regresión (`LinearRegression`, `DecisionTreeRegressor`, `RandomForestRegressor`) y métricas (`r2_score`, `mean_squared_error`).

Bloque 1: Carga de Datos, Traducción y EDA Inicial

Objetivo: Cargar el dataset crudo `cardekho.csv` y adecuarlo mediante traducción al español latino.
Detalles y Funcionalidad: Se renombraron columnas clave (ej. `selling_price` a `precio_venta`, `km_driven` a `kilometros_recorridos`). Mediante `.info()` y `.describe()` se inspeccionaron 8,128 filas, identificando la presencia de valores nulos y distribuciones numéricas.

Bloque 2: Preprocesamiento e Ingeniería de Características

Objetivo: Limpiar anomalías, tratar nulos, codificar variables categóricas y escalar características.
Detalles y Funcionalidad: Se convirtió `potencia_maxima` a numérica, se imputaron nulos con la mediana para evitar sesgos, se aplicó codificación ordinal a `propietarios_anteriores`, *One-Hot Encoding* a variables nominales (combustible, transmisión, tipo de vendedor) y se estandarizó la matriz X con `StandardScaler`, preservando los 8,128 registros en 14 columnas finales.

Bloque 3: División del Dataset (Train/Test Split)

Objetivo: Aislar datos de entrenamiento y prueba para prevenir el sobreajuste y evaluar generalización.

Detalles y Funcionalidad: Se aplicó la función `train_test_split` dividiendo el dataset en 80% para entrenamiento (fit) y 20% para prueba, configurando un `random_state=42` para garantizar absoluta reproducibilidad.

Bloque 4: Entrenamiento de los Tres Modelos de Regresión

Objetivo: Instanciar y entrenar tres algoritmos con enfoques predictivos distintos.

Detalles y Funcionalidad: Se entrenaron secuencialmente la *Regresión Lineal* (modelo lineal base), el *Árbol de Decisión* (no lineal basado en reglas jerárquicas) y *Random Forest* (ensamble robusto), generando sus respectivas predicciones sobre el conjunto de test.

3. Fichas Técnicas de Reportes Gráficos



Gráfico 1: Comparativa de Rendimiento (R^2 Score)

Nombre: Gráfico de barras de Coeficiente de Determinación.

Objetivo: Comparar visualmente la proporción de varianza explicada por cada modelo.

Análisis del Resultado: *Random Forest* lidera contundentemente con un R^2 de **0.9689**, superando al Árbol de Decisión (0.9436) y a la Regresión Lineal (0.6885), lo que demuestra la superioridad del aprendizaje por ensamble frente a relaciones complejas.



Gráfico 2: Valores Reales vs. Valores Predichos

Nombre: Diagramas de dispersión con línea de referencia perfecta ($y = x$).

Objetivo: Contrastar la precisión puntual de las estimaciones frente al valor real en todo el espectro de precios.

Análisis del Resultado: Los puntos correspondientes a *Random Forest* se alinean de manera sumamente estrecha a lo largo de la diagonal roja ideal, evidenciando alta exactitud tanto en vehículos económicos como en gama alta, sin desviaciones severas.

4. Resumen Cuantitativo de Resultados

La siguiente tabla consolida las métricas de evaluación obtenidas en el conjunto de prueba:

Modelo Evaluado	R ² Score (Precisión)	Error Cuadrático Medio (MSE)
Regresión Lineal	0.6885	3.15×10^{11}
Árbol de Decisión	0.9436	5.73×10^{10}
Random Forest (Ganador)	0.9689	3.15×10^{10}

5. Justificación Técnica y Conclusiones Metodológicas

Justificación del Mejor Modelo (Random Forest)

El algoritmo **Random Forest Regressor** fue seleccionado como el mejor modelo debido a su capacidad superior para capturar interacciones no lineales entre las características técnicas de los vehículos (como cilindrada, potencia y año) y su precio de venta. Al promediar múltiples árboles de decisión independientes, mitiga drásticamente el sobreajuste, logrando explicar casi el 97% de la varianza total de los datos (R^2 de 0.9689).

Impacto del Preprocesamiento y Conclusión General

La metodología aplicada demuestra que un riguroso pipeline de preprocesamiento —que incluye la correcta imputación de nulos, la codificación lógica de variables ordinales y nominales, y la estandarización numérica— es un habilitador crítico para el éxito del aprendizaje supervisado. El flujo desarrollado cumple a cabalidad con los estándares del Bootcamp, proporcionando una solución robusta, escalable y totalmente replicable para la valoración automatizada de activos automotrices.