

Guía de Sustentación

Proyecto Final - Ciencia de Datos (Bootcamp BIT)

Estudiante: Pablo Montenegro

Línea de trabajo: Aprendizaje Supervisado - Regresión

Fecha de entrega: 5 de octubre

BLOQUE 1 · Planteamiento del Problema

La idea original del proyecto era medir el crecimiento histórico de la demanda laboral de los roles **Analista de Datos** y **Científico de Datos**, y proyectar esa demanda hacia el futuro, para justificar por qué vale la pena orientarse hacia esas carreras.

Antes de modelar, se hizo una validación exploratoria y se encontró que **el volumen de vacantes no muestra una tendencia de crecimiento real** (la correlación entre año y cantidad de vacantes es cercana a cero, incluso ligeramente negativa). Se revisó también si el salario mostraba una tendencia temporal, y tampoco la hay. Por esta razón, el proyecto se reorientó hacia una pregunta distinta pero igual de relevante:

¿qué variables determinan el salario de una oferta de empleo en el sector tecnológico, y qué tan bien se puede predecir ese salario?

Idea clave para mencionar en la sustentación:

- El cambio de enfoque no fue un tropiezo, fue una decisión basada en evidencia: se validó la premisa inicial contra los datos y, como no se sostenía, se ajustó el objetivo en vez de forzar una conclusión que los datos no respaldaban.

BLOQUE 2 · Dataset y Variables

Se usó el dataset **AI Job Market Dataset** (10.345 registros, 19 columnas, sin valores nulos). Las columnas se tradujeron al español para facilitar la explicación. Las variables usadas para el modelo final fueron: **cargo**, **nivel_experiencia**, **pais**, **modalidad** y las cinco habilidades técnicas (**skill_python**, **skill_sql**, **skill_ml**, **skill_deep_learning**, **skill_cloud**). La variable objetivo (a predecir) es **salario**.

Decisión importante: se descartó **anos_experiencia** (el número de años) como variable, porque en la exploración se encontró que no tiene relación real con el salario (correlación casi cero), mientras que **nivel_experiencia** (Entry / Mid / Senior) sí la tiene, y de forma muy clara.

Además, por sugerencia del profesor —con la intención de alejar un poco el modelo de la normalidad casi perfecta propia de un dataset sintético—, se aplicó **StandardScaler** a las 5 variables de skills (python, sql, ml,

deep_learning, cloud). Se verificó que esto no cambia el desempeño del modelo lineal (el R^2 es idéntico con o sin esta estandarización, ya que un modelo lineal es matemáticamente invariante a la escala de sus variables), pero sí cambia cómo se interpretan sus coeficientes: en vez de representar "tener la skill vs. no tenerla", cada coeficiente representa el efecto de una variación de una desviación estándar en esa skill.

BLOQUE 3 · Exploración de Datos (EDA)

Hallazgos visuales clave a mencionar:

- El salario se distribuye de forma aproximadamente normal, entre \$40.000 y \$200.000, sin valores atípicos que requirieran limpieza.
- El boxplot por nivel de experiencia muestra una progresión clara: Entry (~\$89.000) → Mid (~\$113.000) → Senior (~\$138.000).
- El salario promedio por cargo muestra dos grupos: AI Engineer y Machine Learning Engineer muy por encima (~\$140.000), y Business Analyst, Data Engineer, Data Scientist y Data Analyst agrupados y casi empatados entre sí (~\$99.000-\$102.000).

BLOQUE 4 · Preprocesamiento

Se seleccionaron las variables, se aplicó **One-Hot Encoding** a las categóricas (cargo, nivel_experiencia, pais, modalidad) para convertirlas en columnas numéricas de 0 y 1, y se dividió el dataset en 80% entrenamiento (8.276 registros) y 20% prueba (2.069 registros), usando **random_state=42** para que el resultado sea reproducible.

BLOQUE 5 · Modelado y Resultados

Se entrenaron y compararon tres modelos de regresión:

Modelo	MAE (USD)	RMSE (USD)	R2
Regresión Lineal	7,593.45	9,232.67	0.9144
Gradient Boosting	7,611.80	9,253.81	0.9140
Random Forest	8,298.09	10,487.25	0.8895

Ganador: Regresión Lineal. El hecho de que un modelo simple supere a modelos más complejos (Random Forest, Gradient Boosting) es, en sí mismo, un hallazgo: indica que la relación entre las variables y el salario es mayormente **lineal** en este dataset.

Variables con mayor impacto en el salario (coeficientes del modelo ganador):

Variable	Impacto	Dirección
cargo = AI Engineer	+\$27,041	Aumenta
cargo = Machine Learning Engineer	+\$26,372	Aumenta
nivel_experiencia = Senior	+\$24,950	Aumenta
skill_ml (escalada)	+\$7,460	Aumenta
skill_deep_learning (escalada)	+\$7,367	Aumenta
skill_cloud (escalada)	+\$4,834	Aumenta
pais / modalidad	±\$300 máx.	Casi nulo
cargo = Data Analyst / Data Scientist	-\$13,341 / -\$13,465	Reduce
nivel_experiencia = Entry	-\$24,995	Reduce

Nota sobre la escala de las skills: como *skill_ml*, *skill_deep_learning* y *skill_cloud* fueron estandarizadas (StandardScaler), su coeficiente está en una unidad distinta a las variables categóricas (0/1 por One-Hot Encoding). Para estimar el efecto real de "tener la skill" frente a "no tenerla", se multiplica aproximadamente por 2 (la desviación estándar de una variable binaria balanceada es $\approx 0,5$). Ejemplo: *skill_ml* con coeficiente $\sim \$7,460$ equivale a un efecto aproximado de $\sim \$14,920$ al comparar tenerla vs. no tenerla.

Mensaje de cierre para la sustentación: el cargo y la seniority pesan mucho, pero las skills técnicas (ML, Deep Learning, Cloud) también representan un salto salarial importante y **sí son algo que un Analista o Científico de Datos puede desarrollar**, sin necesidad de cambiar de rol.

*Nota técnica a mencionar sobre el gráfico de predicciones vs. valores reales: los puntos no forman una nube uniforme, forman **bandas diagonales**. Esto ocurre porque el salario está determinado casi exactamente por combinaciones discretas de variables categóricas (cargo + experiencia + país); cada banda agrupa ofertas con la misma combinación de características.*

BLOQUE 6 · Conclusiones

- El enfoque se replanteó con evidencia: no hay tendencia de crecimiento real en la demanda ni en el salario de estos roles en el dataset analizado.
- La Regresión Lineal fue el mejor modelo ($R^2=0.9144$), lo que indica que la relación entre las variables y el salario es mayormente lineal.
- El cargo y el nivel de experiencia Senior son los factores de mayor impacto positivo; las skills de ML, Deep Learning y Cloud también aportan un incremento salarial relevante.
- El dataset tiene características de datos sintéticos (fechas hasta 2026, variables sin relación temporal real), por lo que las conclusiones reflejan patrones del dataset modelado, y se recomienda validarlas con datos reales del mercado laboral.

ANEXO · Guía de los Gráficos del Notebook

1. Distribución del Salario (USD)

Objetivo: Ver cómo se reparten los salarios del dataset antes de modelar: si hay sesgos fuertes, valores atípicos, o si se asemeja a una distribución normal.

Análisis de resultados: La distribución es aproximadamente normal, entre \$40,000 y \$200,000, sin valores atípicos extremos que hubieran requerido limpieza o transformación adicional antes de modelar.

2. Salario según Nivel de Experiencia (boxplot)

Objetivo: Confirmar visualmente si nivel_experiencia tiene relación con el salario, antes de decidir incluirla como variable del modelo.

Análisis de resultados: Progresión clara y ordenada: Entry (~\$89,000) → Mid (~\$113,000) → Senior (~\$138,000). Hay algo de traslape entre las cajas, pero las medianas muestran una tendencia consistente que respalda usar esta variable en el modelo.

3. Salario Promedio por Cargo

Objetivo: Comparar el salario promedio entre los 6 cargos del dataset, para identificar si existen grupos diferenciados de remuneración.

Análisis de resultados: Se identifican dos grupos: AI Engineer y Machine Learning Engineer muy por encima del resto (~\$140,000); Business Analyst, Data Engineer, Data Scientist y Data Analyst casi empatados entre sí (~\$99,000-\$102,000). Este hallazgo fue clave para reorientar el objetivo del proyecto hacia la predicción salarial.

4. Mapa de Calor: Correlación entre Variables Numéricas y el Salario

Objetivo: Sugerencia del profesor: cuantificar la relación lineal entre el salario y cada variable numérica, y de paso revisar si existe multicolinealidad entre las skills (es decir, si alguna skill duplica la información de otra).

Análisis de resultados: Solo skill_deep_learning (0.24), skill_ml (0.23) y skill_cloud (0.15) muestran una correlación débil-moderada con el salario; skill_python, skill_sql, anos_experiencia y vacantes_disponibles están prácticamente en cero. Entre las skills entre sí, todas las correlaciones también son cercanas a cero, lo que descarta multicolinealidad: cada skill aporta información independiente.

5. Comparación de R^2 entre Modelos

Objetivo: Comparar visualmente el desempeño (R^2) de los tres modelos entrenados, para identificar el ganador de un vistazo.

Análisis de resultados: Regresión Lineal y Gradient Boosting quedan prácticamente empatados (~0.91), mientras que Random Forest se queda un escalón abajo (~0.89). Confirma que la relación entre las variables y el salario es mayormente lineal.

6. Regresión Lineal: Predicciones vs. Valores Reales

Objetivo: Evaluar visualmente qué tan bien predice el mejor modelo, comparando sus predicciones contra los valores reales de salario del conjunto de prueba.

Análisis de resultados: Los puntos se agrupan cerca de la línea de predicción perfecta, aunque forman bandas diagonales en vez de una nube uniforme. Esto ocurre porque el salario está determinado casi exactamente por combinaciones discretas de variables categóricas (cargo + experiencia + país); cada banda agrupa ofertas con la misma combinación de características.

7. Variables con Mayor Impacto en el Salario (coeficientes)

Objetivo: Interpretar el modelo ganador, identificando qué variables aumentan o reducen más el salario predicho.

Análisis de resultados: cargo = AI Engineer / Machine Learning Engineer y nivel_experiencia = Senior son los de mayor impacto positivo; las skills de ML, Deep Learning y Cloud también contribuyen de forma relevante; país y modalidad son casi irrelevantes; nivel_experiencia = Entry y cargo = Data Analyst / Data Scientist reducen el salario esperado frente al promedio.